Day 56 非監督式機器學習

K-mean 觀察：使用輪廓分析

出題教練 陳明佑

知識地圖 非監督學習

CUPOY

機器學習概論 Introduction of Machine Learning

監督式學習
Supervised Learning

前處理 Processing → 探索式數據分析 Exploratory Data Analysis → 特徵工程 Feature Engineering → 模型選擇 Model selection → 參數調整 Fine-tuning → 集成 Ensemble

非監督式學習
Unsupervised Learning

分群 Clustering

降維 Dimension Reduction

非監督學習
Unsupervised learning

非監督簡介

分群 Clustering

- K-平均算法 K-Mean
- 階層分群法 Hierarchical Clustering

降維 Dimension Deduction

- 主成分分析PCA(Principal components analysis)
- T 分佈隨機近鄰嵌入 t-SNE

本日知識點目標

- 大致了解輪廓分析的設計想法與用途
- 如何使用輪廓分析觀察 K-mean 效果

註：因為非監督模型的效果，較難以簡單的範例看出來，所以非監督偶數日提供的檢視工具，僅供觀察非監督模型的效果，與後續其他部分及程式寫作無關，同學只要能感受到這些非監度模型的效果即可，不用執著於完全搞懂該章節所使用的工具

分群模型的評估

CUPOY

- 最大困難
  - 與監督模型不同，非監督因為沒有目標值，因此無法使用目標值的預估與實際差距，來評估模型的優劣
- 評估方式類型
  - 有目標值的分群
    - 如果資料有目標值，只是先忽略目標值做非監督學習，則只要微調後，就可以使用原本監督的測量函數評估準確性
  - 無目標值的分群
    - 但通常沒有目標值/目標值非常少才會用非監督模型，這種情況下，只能使用資料本身的分布資訊，來做模型的評估

輪廓分析(Silhouette analysis) (1 / 3)

CUPOY

不要被名詞嚇到了，其實輪廓分析是一個很直覺的非監督評估方式，讓我們來看看如何計算吧。

歷史

最早由 Peter J. Rousseeuw 於 1986 提出。它同時考慮了群內以及相鄰群的距離，除了可以評估資料點分群是否得當，也可以用來評估不同分群方式對於資料的分群效果

設計精神

同一群的資料點應該很近，不同群的資料點應該很遠，所以設計一種當 同群資料點越近 / 不同群資料點越遠 時越大的分數

當資料點在兩群交界附近，希望分數接近 0

輪廓分析(Silhouette analysis) (2 / 3)

CUPOY

單點輪廓值

- 對任意單一資料點 i，「與 i 同一群」 的資料點，距離 i 的平均稱為 ai
- 「與 i 不同群」 的資料點中，不同群距離 i 平均中，最大的稱為 bi (其實就是要取第二靠近 i 的那一群平均，滿足交界上分數為 0 的設計)
- i 點的輪廓分數 si : (bi-ai) / max{bi, ai}
- 其實只要不是刻意分錯，bi 通常會大於等於 ai，所以上述公式在此條件下可以化簡為 1 - ai / bi

參考來源：聚類評估算法-輪廓係數

輪廓分析(Silhouette analysis) (3 / 3)

CUPOY

整體的輪廓分析

- 分組觀察 如下圖，左圖依照不同的類別，將同類別的輪廓分數排序後顯示，可以發現黃綠兩組的輪廓值大多在平均以下，且比例上接近 0 的點也比較多，這些情況都表示這兩組似乎沒分得那麼開 (可對照右圖)

- 平均值觀察 計算分群的輪廓分數總平均，分的群數越多應該分數越小，如果總平均值沒有隨著分群數增加而變小，就說明了那些分數數較不洽當

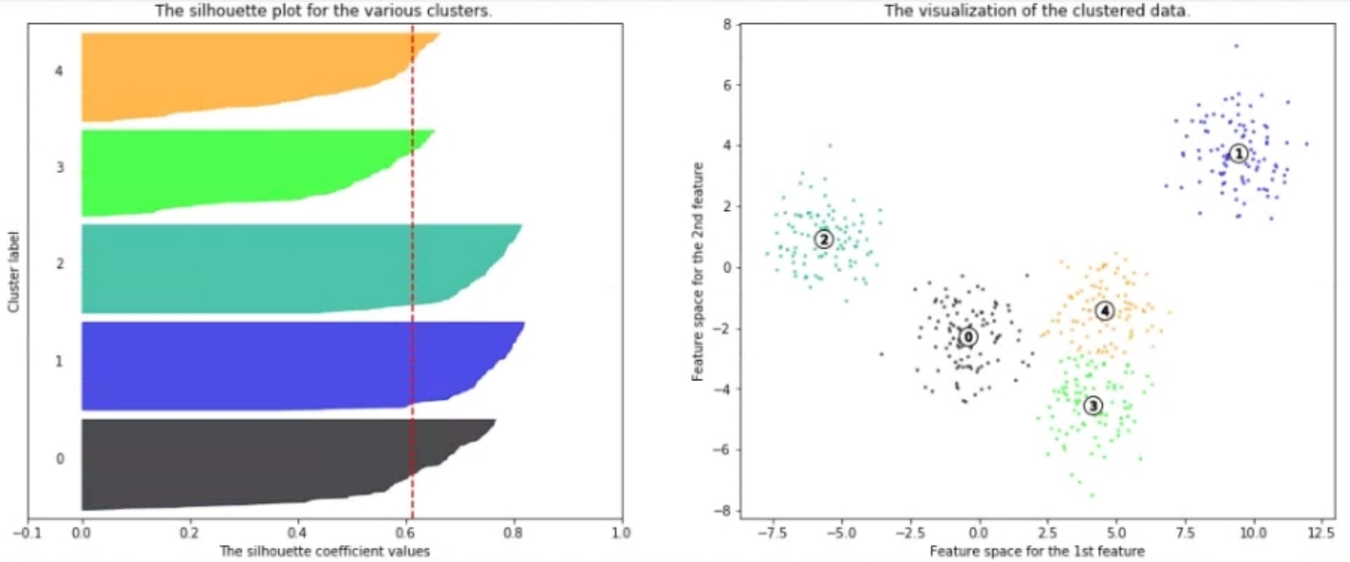

重要知識點複習

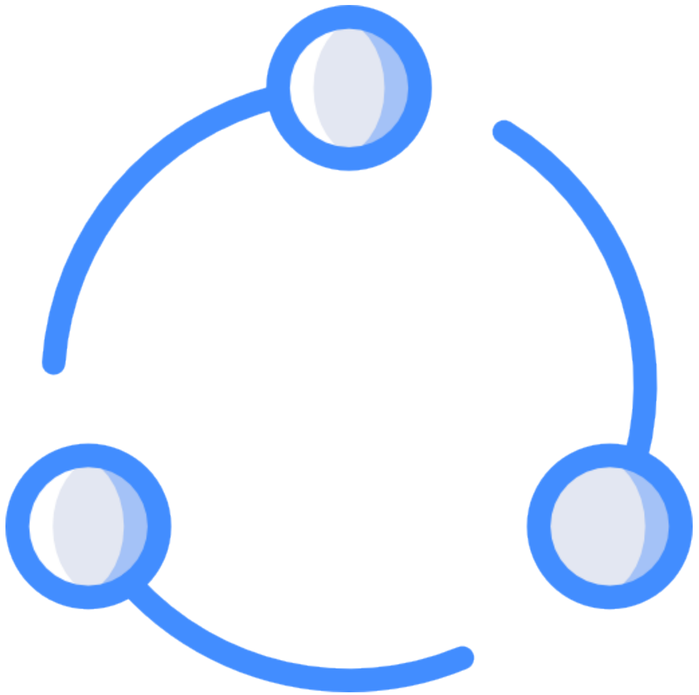

- 輪廓分數是一種 同群資料點越近 / 不同群資料點越遠 時會越小的分數，除了可以評估資料點分群是否得當，也可以用來評估分群效果

- 要以輪廓分析觀察 K -mean，除了可以將每個資料點分組觀察以評估資料點分群是否得當，也可用平均值觀察評估不同 K 值的分群效果

解題時間
Coding Time

請跳出PDF至官網Sample Code & 作業
開始解題